Mapeo de inundaciones con radar Sentinel-1 y U-Net: ablación de supervisión ruidosa y generalización a Lima (marzo de 2017)

Elias Sebastian Villanueva Pinto
Maestría en Inteligencia Artificial, FIIS – Universidad Nacional de Ingeniería
Redes Neuronales y Aprendizaje Profundo, 2026-II – Examen parcial, Pregunta 2

Resumen

Durante una inundación, las nubes inutilizan a los satélites ópticos justo cuando más se los necesita; el radar de apertura sintética (SAR) de Sentinel-1 las atraviesa y adquiere de día y de noche. Implementamos desde cero una U-Net para segmentar el agua píxel a píxel a partir de las bandas VV y VH, y la entrenamos con Sen1Floods11, que combina 446 chips etiquetados a mano por expertos con miles de chips etiquetados automáticamente por umbralización. Un estudio de ablación con presupuesto de cómputo fijo compara (a) entrenar solo con etiquetas doradas frente a añadir etiquetas débiles, (b) cuatro funciones de pérdida y (c) dos variantes arquitectónicas. El mejor modelo (E5b: etiquetas doradas, pérdida Dice y profundidad 3) alcanza un IoU de agua de 0.663 en la prueba en distribución, frente a 0.554 del umbral de Otsu. Las etiquetas débiles no mejoran el rendimiento en distribución, pero en Bolivia, un evento no visto, elevan el IoU de 0.41 a 0.72. Para medir la generalización a una región nunca vista construimos una región de prueba propia para el Perú: la escena Sentinel-1 del 17 de marzo de 2017 sobre Lima —el mismo día de los desbordes del río Rímac en Huachipa y Carapongo— contrastada con la delineación de la activación EMSN038 de Copernicus EMS. Allí el IoU cae a 0.001 en las siete variantes. Un diagnóstico físico muestra que la retrodispersión dentro de los polígonos de EMSN038 (-18.9 dB) está lejos de la del agua abierta (-25.4 dB) y no aumenta al retirarse la inundación: la brecha refleja sobre todo el desajuste de la referencia óptica, que cartografía huellas de lodo días después, más que un fallo del modelo. Cerramos con un análisis cualitativo de los errores característicos del SAR: suelo húmedo, vegetación inundada, doble rebote y sombra de radar.

Palabras clave: segmentación semántica, U-Net, SAR, Sentinel-1, inundaciones, supervisión débil, generalización geográfica, El Niño costero.

1 Introducción y motivación

Entre enero y marzo de 2017, el *Niño costero* provocó lluvias extraordinarias en la costa peruana. En Lima —una ciudad desértica donde casi nunca llueve— los ríos Rímac, Chillón y Huaycoloro se desbordaron y los huaicos afectaron Carapongo, Santa María de Huachipa, Cajamarquilla, Comas, Carabayllo y Puente Piedra. El Servicio de Gestión de Emergencias de Copernicus (EMS) respondió con la activación EMSN038, que delimitó en polígonos las zonas inundadas a partir de imágenes ópticas WorldView-2 del 18 y 21 de marzo [2].

Ese tipo de cartografía es crítica en las horas siguientes al desastre, pero depende de imágenes ópticas que las nubes de tormenta suelen bloquear. El radar de apertura sintética (SAR) de la misión Sentinel-1 [15] emite su propia señal de microondas: atraviesa las nubes y adquiere de noche. Físicamente, el agua tranquila se comporta como un espejo que refleja la señal lejos del satélite (retrodispersión baja, píxeles oscuros), mientras que el suelo rugoso, la vegetación y las

construcciones devuelven más energía. Por eso el SAR es la herramienta *de facto* para el mapeo rápido de inundaciones.

Este trabajo implementa una U-Net [13] para segmentar la extensión del agua a partir de Sentinel-1 y aborda tres preguntas:

1. **Supervisión.** ¿Conviene entrenar solo con pocas etiquetas expertas, o añadir muchas etiquetas automáticas ruidosas?
2. **Diseño.** ¿Qué función de pérdida y qué decisiones arquitectónicas funcionan mejor para un problema con fuerte desbalance de clases?
3. **Generalización.** ¿Qué tan bien transfiere un modelo entrenado en llanuras aluviales de otros continentes a la inundación urbana y por huaicos de Lima?

Contribuciones. (i) Una U-Net propia en PyTorch, configurable en profundidad, conexiones de salto y *upsampling*; (ii) un estudio de ablación con presupuesto de cómputo fijo; (iii) una región de prueba peruana construida a partir de dos fuentes independientes (Sentinel-1 y EMSN038), procesada al mismo formato que el dataset; y (iv) un análisis de la brecha de generalización y de los errores típicos del SAR. Todo el código es reproducible con un único comando.

2 Trabajos relacionados

Segmentación semántica con redes totalmente convolucionales. Long et al. [7] mostraron que una red de clasificación puede convertirse en un predictor denso reemplazando sus capas totalmente conectadas por convoluciones. La U-Net [13] añadió un camino de expansión simétrico y *conexiones de salto por concatenación*, que reinyectan en el decodificador la información espacial fina que el codificador pierde al reducir resolución. Además, propuso entrenar con muy pocas imágenes gracias a un aumento de datos agresivo (deformaciones elásticas) y a una pérdida ponderada por un mapa de pesos que enfatiza los bordes. Sus variantes posteriores incluyen V-Net [9], que introdujo la pérdida Dice para lidiar con el desbalance de clases; U-Net++ [17], con saltos anidados; Attention U-Net [10], con compuertas de atención en los saltos; y nnU-Net [6], que autoconfigura la arquitectura para cada dataset.

Mapeo de inundaciones con SAR. El enfoque clásico umbraliza la retrodispersión, típicamente con el método de Otsu [11] sobre histogramas bimodales, y lo refina con información auxiliar en cadenas automáticas como la de Twele et al. [16]. Estos métodos son rápidos y no requieren entrenamiento, pero confunden el agua con otras superficies oscuras (sombra de radar, pistas, arena seca) y fallan donde el agua no es especularmente lisa. Bonafilia et al. [1] publicaron Sen1Floods11, el primer dataset global georreferenciado para entrenar redes en este problema, e informaron que redes totalmente convolucionales entrenadas con abundantes etiquetas automáticas podían superar a las entrenadas solo con las escasas etiquetas manuales. Para la referencia de agua permanente usamos el mapa global de Pekel et al. [12], y para obtener las escenas, Google Earth Engine [3].

3 Datos

Sen1Floods11. Contiene 11 eventos de inundación en seis continentes, en chips de 512×512 píxeles a 10 m (EPSG:4326) con las bandas VV y VH en dB [1]. Usamos 446 chips con etiqueta *dorada* (agua / no agua / sin datos, anotada por expertos) y la partición oficial: 252 de entrenamiento, 89 de validación y 90 de prueba (eventos vistos), más 15 de Bolivia (evento reservado). Como fuente *débil* tomamos una muestra aleatoria reproducible de 1 500 de los 4 160 chips etiquetados automáticamente por umbral de Otsu sobre VH, excluyendo Bolivia. El agua representa el 9.5 % de los píxeles válidos del entrenamiento dorado, pero el 17.8 % en las etiquetas débiles: un primer indicio de que el umbral sobreestima el agua.

Preprocesamiento. Igual que los autores del dataset, recortamos los dB a $[-50, 1]$ y los escalamos a $[0, 1]$; luego estandarizamos cada banda con media y desviación calculadas *solo* sobre el entrenamiento dorado, para evitar fuga de información. Los píxeles sin datos (etiqueta -1 o SAR no válido) se excluyen de la pérdida y de las métricas.

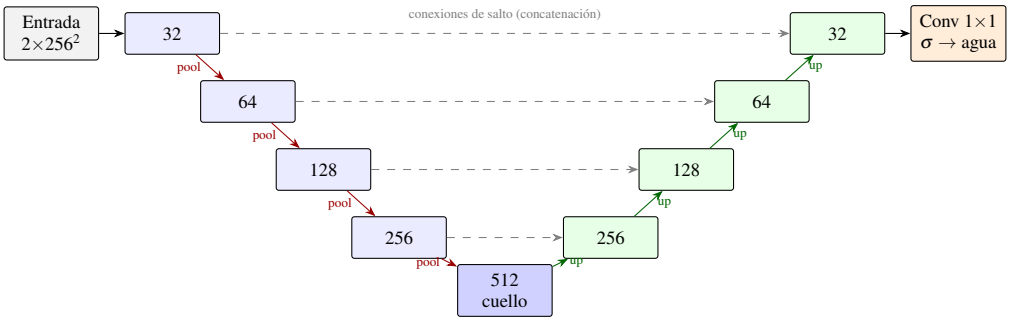


Figura 1: U-Net implementada (`base`=32, profundidad 4; 7.76 M parámetros). Cada bloque: dos convoluciones 3×3 con *padding*, BatchNorm y ReLU. Bajada: *max-pooling* 2×2; subida: convolución transpuesta 2×2; salida: un logit por píxel.

Región de prueba propia: Lima, 17 de marzo de 2017. Sen1Floods11 no incluye eventos peruanos. Buscamos en ASF Vertex todas las escenas Sentinel-1 GRD IW de doble polarización (VV+VH) sobre Lima entre el 10 y el 31 de marzo de 2017 y encontramos tres: 10-mar (otra pasada, antes del evento), **17-mar 10:38 UTC** (Sentinel-1B, órbita relativa 171, descendente) y 29-mar (misma órbita, 12 días después). La del 17 de marzo coincide con el día de los desbordes en Huachipa y Carapongo y precede en un día a la imagen WorldView-2 usada por EMSN038, así que la elegimos como escena de prueba. La obtuvimos de Earth Engine (`COPERNICUS/S1_GRD`), con la calibración, corrección de terreno y conversión a dB con que se construyó Sen1Floods11, y la remuestreamos a su misma grilla (EPSG:4326, 8.98×10^{-5} °). Como etiqueta usamos la capa de extensión de inundación de EMSN038 (`DamAssess_A`, derivada por análisis de objetos sobre la imagen óptica) restringida a la inundación *observada* a lo largo de los ríos (`source = river`, 660 polígonos, 6.34 km²); se excluye la extensión extrapolada hasta la cota máxima del agua. Los polígonos se rasterizaron sobre esa grilla y la escena se recortó en chips de 512×512. Solo se evalúan los píxeles que cumplen tres condiciones: (i) están dentro del área de interés de EMSN038, (ii) están en tierra firme y (iii) no son agua permanente según JRC [12] (ocurrencia $\geq 50\,\%$). Así se excluyen el mar y los cauces permanentes, que EMSN038 no delimita.

Advertencia metodológica. Las etiquetas de EMSN038 no se generaron con el mismo criterio que las doradas: provienen de imágenes ópticas de mucho mayor resolución, de fechas posteriores a la escena SAR y de un proceso orientado a evaluar daños. Las tratamos, por tanto, como *supervisión débil propia* y no como verdad de terreno perfecta; parte de la brecha medida en la Sec. 5.3 se explica por la propia referencia.

4 Metodología

Arquitectura (Fig. 1). Implementamos la U-Net desde cero, sin bibliotecas de segmentación, siguiendo la Fig. 1 de Ronneberger et al. [13] con tres cambios hoy estándar: *padding* = 1 (salida del mismo tamaño que la entrada, sin recortes), BatchNorm [5] e inicialización de He [4]. La entrada tiene dos canales (VV, VH) y la salida, un único logit de agua; para dos clases, *sigmoide* con entropía cruzada binaria es equivalente a *softmax* con dos logits. La implementación permite variar la profundidad, eliminar las conexiones de salto y cambiar el *upsampling* (convolución transpuesta o bilineal).

Funciones de pérdida. Con p la probabilidad predicha, y la etiqueta y v el conjunto de píxeles válidos, comparamos: (i) *BCE*: $\mathscr{L}_{BCE} = -\frac{1}{|v|}\sum_{x \in v}[y \log p + (1-y)\log(1-p)]$; (ii) *Dice* suave [9]: $\mathscr{L}_D = 1 - \frac{2\sum py+1}{\sum p+\sum y+1}$, robusta al desbalance; (iii) su suma, *BCE + Dice*; y (iv) *BCE con peso en bordes*, una adaptación del mapa de pesos de U-Net (Ec. 2 de [13]): $w(x) = 1 + w_0\,(G_\sigma * B)(x)$, donde B marca el borde agua/no-agua, G_σ es un suavizado gaussiano ($\sigma = 3$ px) y $w_0 = 5$. La motivación es que en Lima la inundación ocupa franjas angostas junto a los cauces, donde casi todo es borde.

Aumento de datos. Usamos recortes aleatorios de 256×256 dentro de cada chip, rotaciones

Tabla 1: Estudio de ablación. Todas las corridas usan el mismo presupuesto (3000 pasos, lote 16, recortes de 256 px). La selección se hace con el IoU de agua en *validación* (en negrita el mejor); las columnas de prueba y Bolivia se reportan solo como referencia.

	Datos	Pérdida	Arquitectura	Parám. (M)	IoU val	IoU test	F1 test	IoU Bolivia
E1	dorado	BCE	con saltos, prof. 4	7.76	0.615	0.640	0.781	0.408
E2	dorado + débil	BCE	con saltos, prof. 4	7.76	0.598	0.641	0.781	0.716
E3	dorado	Dice	con saltos, prof. 4	7.76	0.630	0.661	0.796	0.615
E4	dorado	BCE + Dice	con saltos, prof. 4	7.76	0.621	0.656	0.792	0.518
E6	dorado	BCE con peso en bordes	con saltos, prof. 4	7.76	0.624	0.665	0.799	0.598
E5a	dorado	Dice	sin saltos, prof. 4	6.98	0.634	0.649	0.787	0.594
E5b	dorado	Dice	con saltos, prof. 3	1.93	**0.641**	0.663	0.798	0.572

de 90° y volteos. También aplicamos deformaciones elásticas como en Ronneberger et al. [13]: desplazamientos gaussianos ($\sigma = 10$ px) en una grilla 3×3, interpolados de forma bicúbica y aplicados por igual a imagen y máscara. No usamos ajustes de brillo ni contraste, porque en SAR la intensidad es la señal física.

Entrenamiento y selección. AdamW [8] con política *OneCycle* [14] (tasa máxima 2×10^{-3}), lote de 16, precisión mixta y 3000 pasos por corrida. El *presupuesto fijo* es deliberado: así, añadir etiquetas débiles no gana solo por entrenar más tiempo. Al mezclar datos, se muestrea con probabilidad 0.5 desde los chips dorados y 0.5 desde los débiles, para que las 1 500 etiquetas ruidosas no "ahoguen" a las 252 expertas. Se evalúa en validación cada 250 pasos y se conserva el mejor punto según el IoU de agua; ninguna decisión se toma con la partición de prueba.

Métricas. Para la clase agua reportamos IoU $= \frac{TP}{TP+FP+FN}$, F1, precisión, recall, omisión $\frac{FN}{TP+FN}$ y comisión $\frac{FP}{TP+FP}$, las dos últimas siguiendo a Bonafilia et al. [1]. El IoU se da de dos formas: agregado sobre todos los píxeles y promedio por chip, que es la métrica de referencia de los autores del dataset.

Inferencia sobre escenas completas. La escena de Lima ($\sim$5 500$\times$4 000 px) se predice con la estrategia *overlap-tile* de Ronneberger et al. [13]: mosaicos de 512 px con 64 px de margen, de los que solo se conserva el centro, y relleno por reflexión especular en los bordes de la escena.

5 Experimentos y resultados

5.1 Estudio de ablación

La Tabla 1 resume las siete corridas, que tomaron en total unos 63 minutos en una GPU T4. Las curvas de aprendizaje están en la Fig. 2.

(a) Etiquetas doradas frente a doradas + débiles. En validación, entrenar solo con los 252 chips dorados y deformación elástica (E1, IoU 0.615) supera ligeramente a añadir las etiquetas débiles (E2, 0.598); en prueba, ambas quedan empatadas (0.640 frente a 0.641). La diferencia aparece *fuera de distribución*: en Bolivia, E2 alcanza un IoU de 0.716, frente a 0.408 de E1. El cambio se explica casi por completo por el recall (0.788 frente a 0.430), porque la precisión es la misma ($\approx$0.89). El modelo entrenado solo con etiquetas expertas aprende un criterio de "agua" conservador, ajustado a los 10 eventos vistos, y en una región nueva deja de detectar gran parte del agua. Las etiquetas de Otsu, más abundantes, más diversas y sesgadas hacia marcar más agua (17.8 % frente a 9.5 % de los píxeles), corrigen ese sesgo. Los resultados conectan así las dos tesis. En distribución se cumple la de U-Net [13]: pocas etiquetas buenas con aumento agresivo bastan. Para generalizar, en cambio, la cantidad y diversidad de la supervisión débil importa, como observaron Bonafilia et al. [1]. Seleccionar el modelo con la validación en distribución descarta precisamente la opción que mejor generaliza (Sec. 6).

(b) Función de pérdida. Las tres alternativas a la BCE pura obtienen un IoU de validación muy parecido: Dice (E3) 0.630, BCE con peso en bordes (E6) 0.624 y BCE + Dice (E4) 0.621. En prueba el orden se invierte (E6 0.665, E3 0.661, E4 0.656). Durante cada corrida, el IoU de validación oscila hasta $\pm$0.05 entre evaluaciones (Fig. 2), una variación mayor que la diferencia entre estas pérdidas,

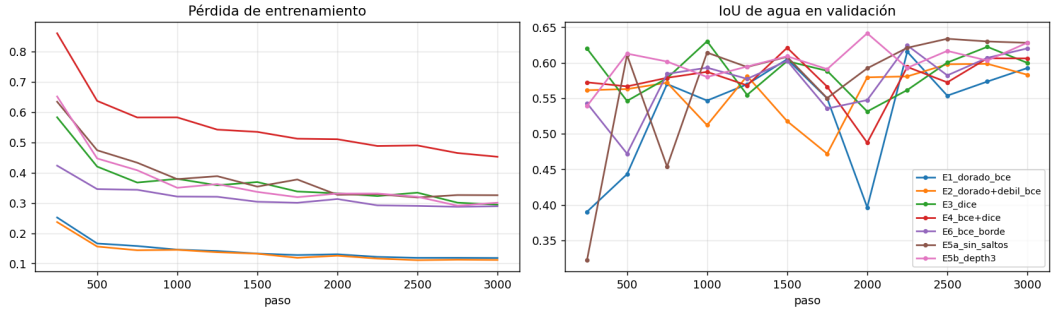


Figura 2: Pérdida de entrenamiento (izq.) e IoU de agua en validación (der.) de las siete corridas. La oscilación a mitad del entrenamiento coincide con el máximo de la tasa de aprendizaje de la política OneCycle.

Tabla 2: Clase *agua*: modelo final (E5b) frente a la línea base clásica (umbral de Otsu sobre VH). *test*: chips dorados de los eventos vistos en entrenamiento; *bolivia*: evento nunca visto. IoU agregado sobre todos los píxeles válidos e IoU promedio por chip (métrica de los autores del dataset).

	IoU	IoU/chip	F1	Precisión	Recall	Omisión	Comisión
U-Net (test)	0.663	0.388	0.798	0.821	0.776	0.224	0.179
Otsu VH (test)	0.554	0.332	0.713	0.682	0.748	0.252	0.318
U-Net (bolivia)	0.572	0.352	0.728	0.884	0.618	0.382	0.116
Otsu VH (bolivia)	0.718	0.474	0.836	0.803	0.870	0.130	0.197

de modo que no hay un ganador claro entre las tres. La señal consistente es otra: *todas* superan a la BCE pura (E1) en validación, en prueba (+0.016 a +0.025) y sobre todo en Bolivia (0.52–0.62 frente a 0.41). El mecanismo se ve en la precisión y el recall. Con solo un 9.5 % de píxeles de agua, la BCE produce un modelo conservador (precisión 0.886, recall 0.669 en validación). Dice, al optimizar directamente el solapamiento de la clase minoritaria, y el peso en bordes, al castigar los errores en el contorno, cambian algo de precisión por recall (0.70–0.72). Por su IoU de validación, Dice pasa a la etapa (c).

(c) Arquitectura. Sin conexiones de salto (E5a), el IoU de validación fue de 0.634; con profundidad 3 (E5b), de 0.641. Ninguna de las dos variantes empeora la validación: con un modelo 4 veces más pequeño (1.93 M frente a 7.76 M parámetros), la profundidad 3 obtiene el mejor IoU de validación de todo el estudio y, en prueba, iguala a la red completa (0.663 frente a 0.661). Con solo 252 chips de entrenamiento, la capacidad adicional del quinto nivel no se aprovecha. Además, a 10 m por píxel, tres reducciones (2^3) dan un campo receptivo suficiente para reconocer cuerpos de agua. Quitar las conexiones de salto tampoco degrada el IoU de validación, a diferencia del experimento de la Clase 9, donde sí empeoraba la clase *borde*. Sí cambia el tipo de error: la precisión cae de 0.832 a 0.792 en validación y de 0.827 a 0.799 en prueba, y el IoU de prueba baja de 0.661 a 0.649. Sin la información espacial fina que aportan los saltos, el contorno del agua se predice más “engordado”. Que el efecto sea pequeño se explica porque el IoU agregado está dominado por cuerpos de agua grandes y homogéneos, para los que una localización gruesa basta. El modelo final, elegido por validación, es E5b (dorado, Dice, profundidad 3).

5.2 Evaluación en distribución

El modelo final (E5b) obtiene en la prueba en distribución un IoU de 0.663, F1 de 0.798, precisión de 0.821 y recall de 0.776 (Tabla 2, Fig. 3). Frente al umbral de Otsu, la U-Net sube el IoU de 0.554 a 0.663 y reduce la comisión de 0.318 a 0.179, sin perder recall (0.776 frente a 0.748): aprende a no confundir con agua otras superficies oscuras, que el umbral marca indiscriminadamente. La matriz de confusión (Fig. 3) muestra que el 97.6 % de los píxeles de no-agua y el 77.6 % de los de agua

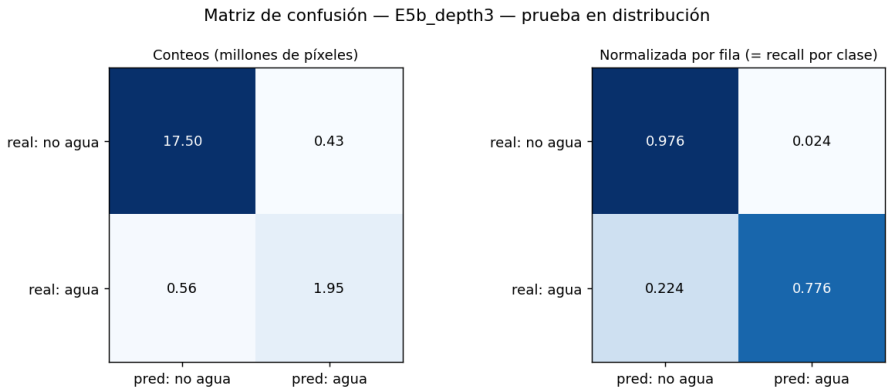


Figura 3: Matriz de confusión del modelo final en la prueba en distribución (90 chips dorados). Izquierda: conteos en millones de píxeles; derecha: normalizada por fila (recall por clase).

Tabla 3: Generalización geográfica: el modelo entrenado solo con Sen1Floods11 evaluado sobre Lima (Sentinel-1 del 17-mar-2017 contra la delineación EMSN038), frente a la prueba en distribución.

	IoU	IoU/chip	F1	Precisión	Recall	Omisión	Comisión
Prueba en distribución	0.663	0.388	0.798	0.821	0.776	0.224	0.179
Lima 17-mar-2017 (EMSN038)	0.001	0.010	0.002	0.001	0.006	0.994	0.999
Brecha (Lima − dist.)	-0.662	-0.379	-0.796	-0.820	-0.770	0.770	0.820

se clasifican bien. El error dominante es la omisión: de cada cuatro píxeles de agua, uno queda sin detectar. El IoU promedio por chip (0.388) es mucho menor que el agregado (0.663) porque muchos chips contienen muy poca agua, y en ellos unos pocos píxeles mal clasificados llevan el IoU del chip cerca de cero, mientras que el IoU agregado lo dominan los chips con grandes cuerpos de agua. **En Bolivia la relación se invierte**: Otsu (0.718) supera a la U-Net (0.572), cuyo recall cae a 0.618. Otsu recalcula su umbral a partir del histograma de cada escena y se adapta a la nueva región; la red, en cambio, aplica la relación aprendida en otros eventos. Es un primer aviso de que la generalización geográfica es el punto débil del modelo.

5.3 Generalización geográfica al Perú

Resultado. Sobre Lima, el modelo final obtiene un IoU de 0.001 (precisión 0.001, recall 0.006), frente a 0.663 en distribución (Tabla 3). Solo detecta agua en el 1.7 % de los 293 polígonos EMSN038 evaluables (criterio: $\geq$25 % de su área), y el área evaluable es de 1 709 km², de los cuales 5.98 km² están marcados como inundados. Las siete corridas fallan por igual (IoU entre 0.0003 y 0.013; Tabla 4), con independencia de su desempeño en validación o en Bolivia. E2, la mejor en Bolivia, es incluso la peor en Lima. Ninguna decisión de la ablación cambia el resultado, lo que sugiere una causa común ajena al modelo.

Diagnóstico físico: ¿hay agua visible para el radar? Antes de atribuir la brecha al modelo, comparamos la retrodispersión dentro y fuera de los polígonos (Tabla 4, Fig. 5). Dentro de los polígonos, la mediana de VH es de -18.9 dB, apenas 1.4 dB más oscura que el resto de Lima (-17.5) y lejos de los -25.4 dB del agua de Sen1Floods11. Solo el 35 % de esos píxeles cae por debajo de -20 dB, frente al 78 % del agua de entrenamiento. Si el 17 de marzo hubiera habido una lámina de agua que luego se retiró, la señal debería haber subido varios dB hacia el 29; dentro de los polígonos, en cambio, *bajó* 0.41 dB, mientras que afuera no cambió. Por último, un umbral de Otsu calculado sobre la propia escena (sin entrenamiento) recupera el 72 % de los píxeles marcados, pero con precisión 0.005 (IoU 0.005): la leve oscuridad de los polígonos no se distingue del resto de la ciudad y del desierto. La conclusión es que **el SAR del 17 de marzo no muestra agua abierta donde EMSN038 marca inundación**.

Tabla 4: Izquierda: IoU de cada corrida en validación, prueba, Bolivia y Lima. Derecha: diagnóstico físico de la escena de Lima, con la mediana de retrodispersión en dB.

	Val	Test	Bolivia	Lima
E1	0.615	0.640	0.408	0.007
E2	0.598	0.641	**0.716**	0.000
E3	0.630	0.661	0.615	0.008
E4	0.621	0.656	0.518	0.007
E6	0.624	**0.665**	0.598	**0.013**
E5a	0.634	0.649	0.594	0.003
E5b	**0.641**	0.663	0.572	0.001

VH (dB)	Agua/inund.	Resto
Sen1Floods11	−25.4	−16.0
Lima 17-mar	−18.9	−17.5
Lima 29-mar	−19.3	−17.4

Cambio 29−17 mar: −0.41 (dentro) / +0.05 (fuera)
Otsu escena: IoU 0.005, P 0.005, R 0.725

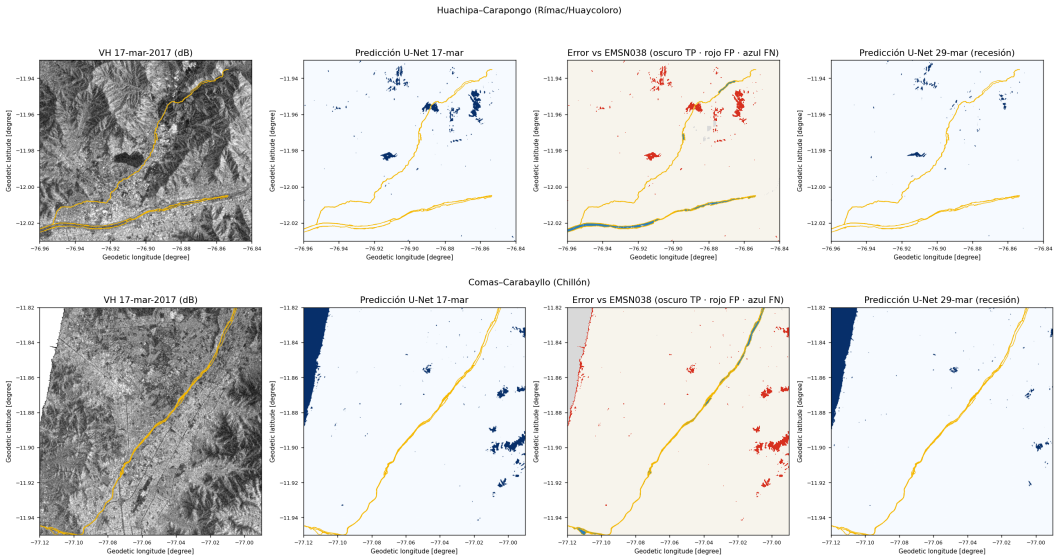


Figura 4: Lima, 17 y 29 de marzo de 2017. Arriba: Huachipa–Carapongo (ríos Rímac y Huaycoloro); abajo: Comas–Carabayllo (río Chillón). De izquierda a derecha: VH (dB), predicción del 17-mar, mapa de error frente a EMSN038 (oscuro = acierto, rojo = falso positivo, azul = falso negativo) y predicción del 29-mar. En amarillo, el contorno de los polígonos EMSN038.

Hipótesis sobre la brecha, contrastadas con la evidencia.

1. **Desajuste temporal y de sensor de la referencia (respaldada).** EMSN038 delinea por análisis de objetos (OBIA) sobre WorldView-2 (óptico, submétrico) del 18 y 21 de marzo, mientras que el SAR es del 17 de marzo a las 05:38 hora local. Los huaicos y desbordes duran horas, y lo que la imagen óptica registra días después son *huellas* de la inundación. La ausencia de un aumento de retrodispersión entre el 17 y el 29 de marzo dentro de los polígonos (−0.41 dB) indica que el 17 tampoco había una lámina de agua que luego se retirara.
2. **Lodo frente a agua abierta (respaldada).** Dentro de los polígonos, el VH tiene una distribución estrecha centrada en −18.9 dB, típica de superficies algo más lisas que la ciudad (cauces de grava, barro y depósitos de huaico), y no los −25 dB del agua abierta. Los huaicos son flujos de lodo de superficie rugosa, muy distintos de las llanuras aluviales de Sen1Floods11.
3. **Geometría del radar (respaldada).** La mayoría de los falsos positivos se concentran en manchas sobre las laderas de los cerros de Huachipa, Cajamarquilla y Carabayllo (Fig. 4): son *sombras de radar* en las pendientes opuestas al sensor, en órbita descendente. Ningún evento de entrenamiento está en un relieve tan abrupto.
4. **Escala y desbalance extremo (respaldada).** La inundación delineada son franjas de 100–200 m a

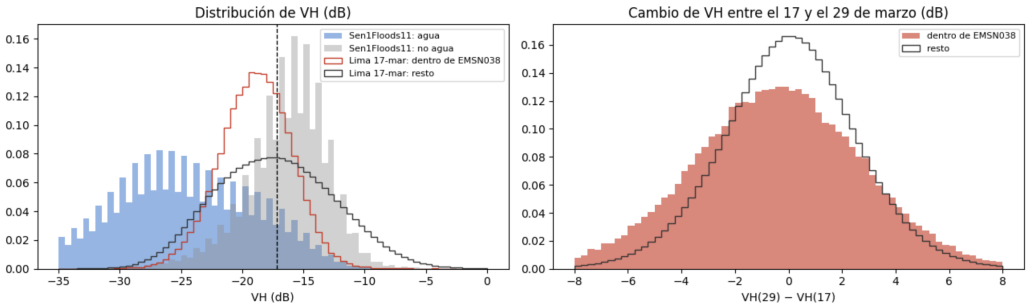


Figura 5: Diagnóstico físico de la región de Lima. Izquierda: distribución de VH dentro de los polígonos EMSN038 (rojo), en el resto del área evaluable (negro) y en el agua y no-agua de Sen1Floods11 (azul y gris); la línea discontinua es el umbral de Otsu de la escena (-17.2 dB). Derecha: cambio de VH entre el 17 y el 29 de marzo (misma órbita).

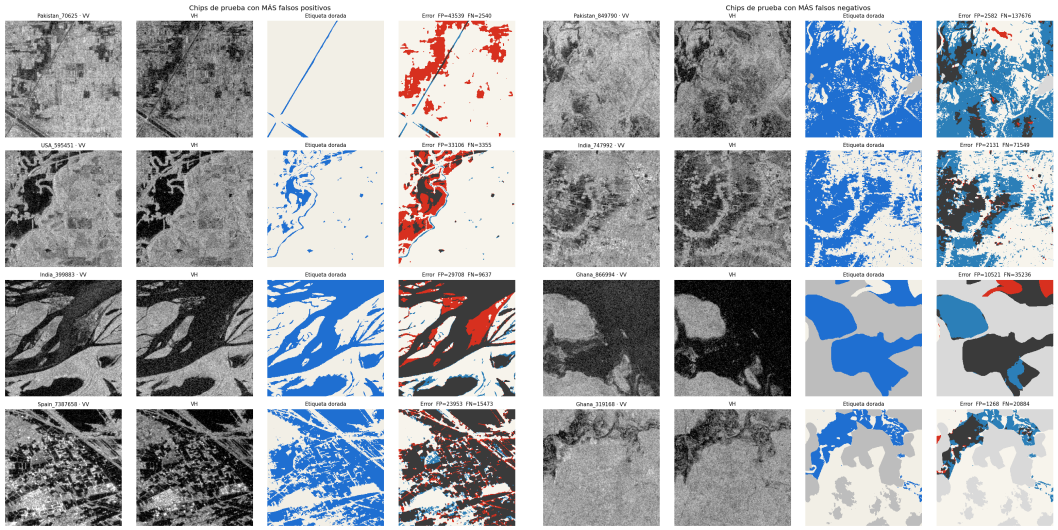


Figura 6: Chips de prueba con más falsos positivos (izq.) y más falsos negativos (der.). Columnas: VV, VH, etiqueta dorada y mapa de error (gris oscuro = acierto agua, rojo = FP, azul = FN).

lo largo de los cauces, que ocupan el 0.35 % del área evaluable (frente al 9.5 % en Sen1Floods11). Con 285 píxeles secos por cada inundado, una tasa de falsos positivos de apenas 1.65 % basta para que estos superen en número a los aciertos, aunque el modelo acierte el 98 % del área seca.

5. **Cobertura urbana y doble rebote (no verificable).** Las zonas afectadas incluyen áreas urbanas donde el agua entre edificaciones devolvería una señal brillante. Con la referencia disponible no es posible aislar este efecto de los anteriores.

En conjunto, la brecha de Lima mide sobre todo el desacuerdo entre dos definiciones de inundación: la del modelo y de Sen1Floods11 (agua abierta visible para el radar en el instante de adquisición) y la de EMSN038 (área afectada, cartografiada en imágenes ópticas días después). No es posible atribuirla solo a una falla del modelo: un método sin entrenamiento también fracasa y la propia señal no contiene agua donde la referencia la marca.

5.4 Análisis cualitativo de errores característicos del SAR

Los chips de prueba con más errores (Fig. 6) muestran cuatro patrones:

1. **Superficies lisas no inundadas → falsos positivos.** En `Pakistan_70625`, la etiqueta solo marca un canal, pero el modelo predice agua en parcelas oscuras: campos recién regados, suelo húmedo o sin vegetación, cuya superficie lisa también refleja la señal lejos del sensor. Es la confusión

clásica entre suelo húmedo y agua abierta, y el SAR por sí solo no puede resolverla.

2. **Vegetación inundada → falsos negativos.** En `Pakistan_849790` e `India_747992`, grandes zonas etiquetadas como agua aparecen en gris medio y no en negro: hay agua bajo cultivos o vegetación. La señal rebota entre la superficie del agua y los tallos (*doble rebote*) y vuelve con más energía, de modo que el agua "no se ve oscura" y el modelo la omite. Es la principal fuente de omisión del modelo.
3. **Mosaicos urbano-agrícolas → errores de borde y doble rebote urbano.** En `Spain_7387658` se mezclan los dos tipos de error: falsos positivos finos en los bordes de parcelas y caminos, y falsos negativos dentro del casco urbano. Ahí las edificaciones con agua alrededor producen un doble rebote brillante. Es el escenario más parecido al de Lima.
4. **Errores de la propia etiqueta.** En `Ghana_866994`, la etiqueta dorada está formada por polígonos suavizados y con grandes zonas sin datos (nubes en la imagen óptica de referencia), y en `USA_595451` e `India_399883` hay zonas muy oscuras y contiguas al río que no se marcaron como agua. Parte de los "errores" son desacuerdos con una referencia imperfecta: también las etiquetas doradas tienen ruido.

La sombra de radar no aparece en estos chips, porque los eventos de Sen1Floods11 están en llanuras; sí es relevante en el valle encajonado del Rímac (Sec. 5.3).

6 Discusión crítica y limitaciones

- **Una sola semilla.** Por restricciones de cómputo, cada configuración se entrenó una vez. Diferencias de uno o dos centésimos de IoU entre corridas están dentro de la variabilidad esperable entre semillas y no deben leerse como concluyentes. Lo correcto sería repetir cada corrida con 3–5 semillas y reportar media y desviación.
- **Presupuesto fijo y subconjunto débil.** Usamos 1 500 de los 4 160 chips débiles disponibles y el mismo número de pasos para todas las corridas. Con más cómputo, las etiquetas débiles podrían rendir más, sobre todo como pre-entrenamiento seguido de ajuste fino con las doradas, que es una alternativa que no exploramos.
- **Referencia peruana imperfecta.** EMSN038 no es verdad de terreno para la fecha del SAR (Sec. 3). La brecha medida mezcla el error del modelo con el error de la referencia; separarlos exigiría una etiqueta manual sobre la propia escena SAR.
- **Solo SAR.** No se realizó la fusión opcional con Sentinel-2. En Lima, además, la nubosidad de marzo de 2017 limitaría la disponibilidad de imágenes ópticas coincidentes.
- **Umbral fijo.** Se usa 0.5 sobre la probabilidad; calibrar el umbral por región podría reducir parte de la brecha.

7 Conclusiones

Implementamos una U-Net propia para mapear agua a partir de Sentinel-1 y la evaluamos en tres niveles de dificultad.

- **En distribución**, el modelo final (profundidad 3, pérdida Dice, solo etiquetas doradas) alcanza un IoU de 0.663 y supera al umbral de Otsu (0.554), sobre todo porque reduce la comisión. Las pérdidas que atienden el desbalance (Dice, BCE + Dice, BCE con bordes) superan a la BCE pura. Una red cuatro veces más pequeña rinde igual que la completa, lo que indica que, con 252 chips, el límite son los datos y no la capacidad.
- **En un evento no visto (Bolivia)**, la elección de supervisión es decisiva. Añadir etiquetas débiles no mejora la validación en distribución, pero sube el IoU en Bolivia de 0.41 a 0.72, porque corrige el recall de un modelo demasiado conservador. Elegir el modelo solo con la validación en distribución descarta justamente la opción que mejor generaliza, y en esa región un umbral adaptativo por escena (Otsu) sigue siendo un competidor fuerte.
- **En Lima**, ninguna variante funciona (IoU $\leq$0.013). El diagnóstico físico muestra que la brecha se explica sobre todo por la referencia, no por el modelo: la escena SAR del 17 de marzo no contiene agua abierta en los polígonos de EMSN038, que cartografían huellas de inundación y

depósitos de huaico vistos en imágenes ópticas días después. Los errores que sí son del modelo, como los falsos positivos por sombra de radar en las laderas, se deben al relieve abrupto, ausente en los datos de entrenamiento.

Para un uso operativo en el Perú se desprenden tres recomendaciones: (i) etiquetar a mano, sobre la propia escena SAR, al menos un evento peruano para validar con una referencia coherente; (ii) incorporar el modelo de elevación (pendiente y máscara de sombra o *layover*) como entrada o filtro; y (iii) para huaicos, que son eventos de horas, combinar la detección de agua con la detección de *cambio* entre una escena previa y una posterior de la misma órbita, en lugar de buscar agua abierta en una sola fecha.

Referencias

[1] D. Bonafilia, B. Tellman, T. Anderson y E. Issenberg. Sen1Floods11: a georeferenced dataset to train and test deep learning flood algorithms for Sentinel-1. En *CVPR Workshops*, 2020.

[2] Copernicus Emergency Management Service. EMSN038: Post-disaster situation analyses of flood and landslides in Lima, Peru. `https://mapping.emergency.copernicus.eu/activations/EMSN038/`, 2017.

[3] N. Gorelick, M. Hancher, M. Dixon, S. Ilyushchenko, D. Thau y R. Moore. Google Earth Engine: planetary-scale geospatial analysis for everyone. *Remote Sensing of Environment*, 202:18–27, 2017.

[4] K. He, X. Zhang, S. Ren y J. Sun. Delving deep into rectifiers: surpassing human-level performance on ImageNet classification. En *ICCV*, 2015.

[5] S. Ioffe y C. Szegedy. Batch normalization: accelerating deep network training by reducing internal covariate shift. En *ICML*, 2015.

[6] F. Isensee, P. F. Jaeger, S. A. A. Kohl, J. Petersen y K. H. Maier-Hein. nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation. *Nature Methods*, 18:203–211, 2021.

[7] J. Long, E. Shelhamer y T. Darrell. Fully convolutional networks for semantic segmentation. En *CVPR*, 2015.

[8] I. Loshchilov y F. Hutter. Decoupled weight decay regularization. En *ICLR*, 2019.

[9] F. Milletari, N. Navab y S.-A. Ahmadi. V-Net: fully convolutional neural networks for volumetric medical image segmentation. En *3DV*, 2016.

[10] O. Oktay et al. Attention U-Net: learning where to look for the pancreas. En *MIDL*, 2018.

[11] N. Otsu. A threshold selection method from gray-level histograms. *IEEE Trans. Systems, Man, and Cybernetics*, 9(1):62–66, 1979.

[12] J.-F. Pekel, A. Cottam, N. Gorelick y A. S. Belward. High-resolution mapping of global surface water and its long-term changes. *Nature*, 540:418–422, 2016.

[13] O. Ronneberger, P. Fischer y T. Brox. U-Net: convolutional networks for biomedical image segmentation. En *MICCAI*, 2015.

[14] L. N. Smith y N. Topin. Super-convergence: very fast training of neural networks using large learning rates. En *Proc. SPIE 11006*, 2019.

[15] R. Torres et al. GMES Sentinel-1 mission. *Remote Sensing of Environment*, 120:9–24, 2012.

[16] A. Twele, W. Cao, S. Plank y S. Martinis. Sentinel-1-based flood mapping: a fully automated processing chain. *International Journal of Remote Sensing*, 37(13):2990–3004, 2016.

[17] Z. Zhou, M. M. R. Siddiquee, N. Tajbakhsh y J. Liang. UNet++: a nested U-Net architecture for medical image segmentation. En *DLMIA*, 2018.